

Lộ trình EDA – từ dữ liệu thô đến kết luận

Sep 23, 2026 · @Someone

Mỗi bài EDA nên đi qua 7 bước cố định (0 → 6), và **mỗi bước phải kết thúc bằng một kết luận viết thành chữ**, không chỉ có code và biểu đồ.

- **Phần 1** là mục lục: dùng làm khung tiêu đề markdown cho notebook mới.
- **Phần 2** giải thích từng mục: làm gì, code mẫu, cách đọc kết quả, mẫu câu kết luận.
- Tiêu đề viết bằng tiếng Anh (dùng luôn trong notebook), giải thích viết bằng tiếng Việt.
- Ví dụ lấy từ bài *Gaming & Academic Performance* để dễ đổi chiều.

flowchart LR

```
A[0. Problem] --> B[1. Understand]
B --> C[2. Quality & Clean]
C --> D[3. Univariate]
D --> E[4. Bivariate]
E --> F[5. Multivariate]
F --> G[6. Summary]
F -. phát hiện lỗi mới .-> C
```

EDA không phải đường thẳng: khi phân tích ở bước 4–5 mà phát hiện điều lạ (như `stress_level` là cột được tạo từ quy tắc), hãy quay lại bước 2 để ghi nhận.

Phần 1 – Mục lục (Table of Contents)

1. 0. Problem Definition & Setup

- a. 0.1. Objective & research questions
- b. 0.2. Import libraries & load data

2. 1. Data Understanding

- a. 1.1. Dataset overview (shape, head, dtypes)
- b. 1.2. Variable dictionary
- c. 1.3. Define target, numerical & categorical features
- d. 1.4. Summary statistics

3. 2. Data Quality & Cleaning

- a. 2.1. Missing values
- b. 2.2. Duplicates

- c. 2.3. Data types & format
- d. 2.4. Invalid values (domain rules)
- e. 2.5. Categorical consistency
- f. 2.6. Outliers
- g. 2.7. Cleaning decisions log

4. 3. Univariate Analysis

- a. 3.1. Target variable
- b. 3.2. Numerical features
- c. 3.3. Categorical features

5. 4. Bivariate Analysis

- a. 4.1. Numerical features vs target
- b. 4.2. Categorical features vs target
- c. 4.3. Feature vs feature (hypothesis-driven)

6. 5. Multivariate Analysis

- a. 5.1. Correlation matrix
- b. 5.2. Multicollinearity (VIF)
- c. 5.3. Confounding & interaction
- d. 5.4. Multivariable check (baseline model)

7. 6. Summary & Next Steps

- a. 6.1. Key findings
- b. 6.2. Data quality issues
- c. 6.3. Limitations
- d. 6.4. Recommendations for modelling

8. Appendix

- a. A. English conclusion templates
- b. B. Final checklist

Phần 2 – Chi tiết từng mục

Mỗi mục gồm: **Mục đích** (tại sao làm), **Làm gì** (các bước + code), **Kết luận cần viết** (câu hỏi mà phần kết luận phải trả lời).

0. Problem Definition & Setup

0.1. Objective & research questions

- **Mục đích:** biết mình đang tìm gì. Không có câu hỏi thì EDA sẽ thành "vẽ tất cả mọi thứ" mà không có kết luận.
- **Làm gì:** viết 1 câu mục tiêu và 3-5 câu hỏi cụ thể ở đầu notebook.
- **Ví dụ:** *Goal: identify which student habits are associated with grades.* Câu hỏi: Does gaming time lower grades? Does game genre matter? Is sleep related to grades?
- **Kết luận cần viết:** không có - nhưng mục 6.1 cuối bài phải trả lời đúng các câu hỏi này.

0.2. Import libraries & load data

- **Làm gì:** import một lần ở đầu (không import rải rác giữa bài), đọc dữ liệu, xem `head()`.

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt, seaborn as sns
from scipy import stats

data = pd.read_csv('data.csv')
data.head()
```

1. Data Understanding

1.1. Dataset overview

- **Mục đích:** biết kích thước và kiểu dữ liệu của từng cột.
- **Làm gì:** `data.shape`, `data.info()`. Kiểm tra cột số có bị đọc thành `object` không (dấu hiệu có ký tự lạ như "N/A", "12,5").
- **Kết luận cần viết:** bao nhiêu dòng, bao nhiêu cột, mấy cột số / chữ, kiểu dữ liệu có đúng không.

1.2. Variable dictionary

- **Mục đích:** hiểu ý nghĩa, đơn vị và **khoảng giá trị hợp lệ** của mỗi cột. Đây là cơ sở để bắt lỗi ở mục 2.4.
- **Làm gì:** lập bảng markdown: tên cột · ý nghĩa · đơn vị · loại (numerical / nominal / ordinal) · khoảng hợp lệ.
- **Ví dụ:** `grades` · điểm tổng kết · điểm · numerical · 0-100; `stress_level` · mức stress · - · ordinal · Low/Medium/High.

1.3. Define target, numerical & categorical features

- **Làm gì:** tạo 3 biến `target`, `num_cols`, `cat_cols`; bỏ cột ID. Với biến ordinal, map sang số theo đúng thứ tự.
- **Lưu ý:** mỗi cột chỉ nên nằm ở một nhóm, hoặc ghi rõ nếu cố ý để ở cả hai.

1.4. Summary statistics

- **Làm gì:** `data.describe().T` cho biến số, `data[cat_cols].nunique()` cho biến chữ.
- **Đọc kết quả thế nào:**
 - So `mean` với `50%` (median): gần nhau → phân phối đối xứng; lệch nhiều → bị lệch (skew).
 - Nhìn `min` / `max` so với khoảng hợp lệ ở 1.2 → phát hiện giá trị vô lý (grades = 118.6, addiction = -4.51).
 - `std` = 0 → cột hằng số, vô dụng.
- **Kết luận cần viết:** phân phối có đối xứng không, cột nào có min/max đáng ngờ (ghi lại để kiểm tra ở mục 2).

2. Data Quality & Cleaning

Mục tiêu: trả lời "dữ liệu có đáng tin để phân tích không?". Mỗi lỗi tìm được phải ghi: **bao nhiêu dòng, bao nhiêu %, xử lý thế nào.**

2.1. Missing values

- **Làm gì:** đếm số lượng và % thiếu mỗi cột. Kiểm tra cả giá trị thiếu "ẩn" như chuỗi rỗng, "?", -1, 999.

```
missing = data.isnull().sum()
(missing / len(data) * 100).round(2)[missing > 0]
```

- **Cách xử lý:** < 5% → xóa dòng hoặc điền median/mode; > 40% → cân nhắc bỏ cột; thiếu có quy luật → thêm cột cờ `is_missing`.
- **Kết luận cần viết:** cột nào thiếu, bao nhiêu %, chọn cách xử lý nào và vì sao.

2.2. Duplicates

- **Làm gì:** kiểm tra trùng **sau khi bỏ cột ID**, và kiểm tra riêng ID có bị trùng không.

```
data.drop(columns='student_id').duplicated().sum()
data['student_id'].duplicated().sum()
```

- **Bẫy hay gặp:** `data.duplicated()` có cả cột ID thì luôn ra 0.

2.3. Data types & format

- **Làm gì:** chuyển cột ngày tháng sang `datetime`, cột số bị đọc thành chữ sang số (`pd.to_numeric(..., errors='coerce')`), biến ordinal sang số có thứ tự.
- **Kiểm tra thêm:** số chữ số thập phân bất thường cũng là dấu hiệu (bài trước: 1.671 điểm có nhiều số lẻ, trong khi các cột khác chỉ có 2).

2.4. Invalid values (domain rules)

- **Mục đích:** bắt giá trị **không thể xảy ra ngoài thực tế**. Đây là bước hay bị bỏ qua nhất.
- **Làm gì:** dùng khoảng hợp lệ ở mục 1.2 để viết luật và đếm số dòng vi phạm.

```
rules = {
    'grades > 100': data['grades'] > 100,
    'addiction_score < 0': data['addiction_score'] < 0,
    'hours per day > 24':
data[['gaming_hours', 'study_hours', 'sleep_hours']].sum(axis=1) > 24,
}
{k: int(v.sum()) for k, v in rules.items()}
```

- **Cách xử lý:** cắt về khoảng hợp lệ (`.clip()`), đặt thành NaN, hoặc xóa dòng. Luôn ghi lại lựa chọn.
- **Chú ý hiệu ứng trần/sàn:** nhiều giá trị đúng bằng 100 hoặc 0 → dữ liệu đã bị cắt (capped).

2.5. Categorical consistency

- **Làm gì:** xem `unique()` và `value_counts()` của từng cột chữ. Tìm lỗi chính tả, viết hoa/thường, khoảng trắng thừa ("Male", "male", "Male ").
- **Cách xử lý:** `.str.strip().str.title()`, hoặc map về tên chuẩn. Nhóm quá nhỏ (< 1-2%) có thể gộp thành "Other".

2.6. Outliers

- **Mục đích:** tìm giá trị **hợp lệ nhưng bất thường**. Khác với 2.4 (giá trị sai).
- **Làm gì:** boxplot + đếm bằng code theo quy tắc IQR, không chỉ nhìn hình.

```
def iqr_outliers(s):
    q1, q3 = s.quantile([.25, .75]); iqr = q3 - q1
    return ((s < q1 - 1.5*iqr) | (s > q3 + 1.5*iqr)).sum()
data[num_cols].apply(iqr_outliers)
```

- **Cách xử lý:** outlier thật (ví dụ học sinh rất giỏi) thì **giữ lại**; chỉ xử lý khi là lỗi hoặc làm hỏng mô hình (dùng log, winsorize).
- **Kết luận cần viết:** "No statistical outliers" không có nghĩa là "no errors" – nói rõ điều này nếu 2.4 có lỗi.

2.7. Cleaning decisions log

- **Mục đích:** người đọc (và chính bạn sau này) biết dữ liệu đã bị thay đổi gì.
- **Làm gì:** một bảng tóm tắt: vấn đề · số dòng · % · cách xử lý. Lưu kết quả vào `data_clean`, không ghi đè `data` gốc.

Issue	Rows	%	Action
grades > 100	134	1.7%	clip to 100
addiction_score < 0	107	1.3%	clip to 0

3. Univariate Analysis

Mục tiêu: mô tả **hình dạng phân phối** của từng biến riêng lẻ. Kết quả bước này quyết định dùng phương pháp nào ở bước 4-5.

3.1. Target variable

- **Mục đích:** hiểu biến quan trọng nhất trước tiên.
- **Làm gì:** histogram + KDE, tính `mean`, `median`, `skew()`.
 - Target là số (regression): phân phối chuẩn không? Có đỉnh lạ (spike) không?
 - Target là nhãn (classification): tỷ lệ các lớp có cân bằng không?
- **Kết luận cần viết:** hình dạng (đối xứng / lệch trái / lệch phải), mean vs median, giá trị bất thường, và **hệ quả:** ví dụ không chuẩn → dùng Spearman / Kruskal-Wallis.

3.2. Numerical features

- **Làm gì:** lưới histogram (+ boxplot) cho tất cả biến số, và bảng `skew()`.
 - Biến số nguyên (tuổi, số con): dùng `sns.histplot(..., discrete=True)`.

- Biến chỉ có 2-5 giá trị: dùng countplot, không dùng boxplot.
- **Độc độ lệch (skewness):** $|\text{skew}| < 0.5 \rightarrow$ gần đối xứng; $0.5-1 \rightarrow$ lệch vừa; $> 1 \rightarrow$ lệch mạnh, cân nhắc biến đổi log.
- **Nhận dạng hình dạng:** normal (chuông), uniform (phẳng), bimodal (2 đỉnh $\rightarrow$ có thể có 2 nhóm ẩn), long tail (đuôi dài).
- **Kết luận cần viết:** gom các biến có cùng hình dạng thành nhóm, thay vì viết từng biến. Ghi lại các điều "lạ" để kiểm tra tiếp (ví dụ: 3 biến có hình thang giống nhau $\rightarrow$ có thể cùng nguồn gốc).

3.3. Categorical features

- **Làm gì:** countplot + bảng tỷ lệ %. Với biến ordinal, đặt `order=[...]` theo đúng thứ tự.

```
for col in cat_cols:
    print(data[col].value_counts(normalize=True).mul(100).round(1), '\n')
```

- **Kết luận cần viết:** nhóm nào chiếm đa số, có mất cân bằng không, nhóm nào quá nhỏ (kết quả cho nhóm đó kém tin cậy). Luôn nêu số %.

4. Bivariate Analysis

Mục tiêu: xem **từng cặp biến** liên quan với nhau thế nào. Chọn phương pháp theo loại biến:

Cặp biến	Biểu đồ	Kiểm định / chỉ số
Số - Số	scatter + LOWESS	Pearson (tuyến tính), Spearman (đơn điệu)
Chữ - Số	boxplot / violin	2 nhóm: t-test, Mann-Whitney; ≥ 3 nhóm: ANOVA, Kruskal-Wallis
Chữ - Chữ	stacked bar, crosstab	Chi-square, Cramér's V

4.1. Numerical features vs target

- **Làm gì:** bảng Pearson + Spearman với target, sắp xếp theo độ mạnh; scatter có `alpha` nhỏ để tránh chồng điểm.
- **Độc độ mạnh $|r|$:** < 0.1 không có; $0.1-0.3$ yếu; $0.3-0.5$ vừa; > 0.5 mạnh.
- **So Pearson với Spearman:** gần nhau $\rightarrow$ quan hệ tuyến tính; Spearman lớn hơn nhiều $\rightarrow$ quan hệ cong nhưng đơn điệu.

- **Kết luận cần viết:** biến mạnh nhất (dương / âm), biến không liên quan, và **kết quả nào ngược trực giác** → đánh dấu để điều tra ở 4.3 / 5.3.

4.2. Categorical features vs target

- **Làm gì:** boxplot từng biến trên subplot riêng, kèm kiểm định và **effect size**.

```
fig, axes = plt.subplots(1, len(cat_cols), figsize=(15, 5))
for ax, col in zip(axes, cat_cols):
    sns.boxplot(data=data, x=col, y=target, ax=ax)
    groups = [g[target] for _, g in data.groupby(col)]
    h, p = stats.kruskal(*groups)
    ax.set_title(f'{col}: p={p:.3g}, eps²={h/(len(data)-1):.3f}')
```

- **Vì sao cần effect size:** với n lớn, p-value gần như luôn < 0.05 dù khác biệt rất nhỏ. ϵ^2 : 0.01 nhỏ, 0.06 vừa, > 0.14 lớn.
- **Kết luận cần viết:** có khác biệt không (p), lớn cỡ nào (effect size), nhóm nào cao nhất / thấp nhất (median của từng nhóm).

4.3. Feature vs feature (hypothesis-driven)

- **Mục đích:** giải thích các kết quả lạ ở 4.1–4.2. Đây là phần tạo ra phát hiện hay nhất.
- **Làm gì:** viết giả thuyết trước, rồi mới vẽ. Ví dụ: *"Reaction time có tương quan dương với điểm có thể do người chơi game nhiều phản xạ nhanh hơn"* → vẽ `gaming_hours` vs `reaction_time_ms`.
- **Kết luận cần viết:** giả thuyết đúng hay sai, và điều đó thay đổi cách hiểu kết quả ở 4.1 ra sao.

5. Multivariate Analysis

Mục tiêu: xem nhiều biến **cùng lúc**, để biết biến nào thật sự quan trọng và biến nào chỉ là "bản sao" của biến khác.

5.1. Correlation matrix

- **Làm gì:** heatmap Spearman của tất cả biến số (có thể kèm target), `annot=True`, `center=0`.
- **Đọc thế nào:** tìm các **cụm** biến tương quan mạnh với nhau ($|p| > 0.7$). Những biến trong một cụm mang cùng thông tin.
- **Kết luận cần viết:** có mấy cụm, gồm biến nào, các biến còn lại có độc lập không.

5.2. Multicollinearity (VIF)

- **Làm gì:** tính VIF **chỉ trên các feature**, không đưa target vào.

```
from statsmodels.stats.outliers_influence import variance_inflation_factor
from statsmodels.tools.tools import add_constant
X = add_constant(data[num_cols])
pd.Series([variance_inflation_factor(X.values, i) for i in
range(X.shape[1])],
          index=X.columns).drop('const').sort_values(ascending=False)
```

- **Đọc VIF:** < 5 ổn; 5-10 cần chú ý; > 10 đa cộng tuyến nghiêm trọng.
- **Kết luận cần viết:** biến nào nên giữ / bỏ cho mô hình tuyến tính, hoặc dùng Ridge/Lasso/PCA.

5.3. Confounding & interaction

- **Confounding (biến gây nhiễu):** A và B có vẻ liên quan, nhưng thực ra cả hai cùng bị C ảnh hưởng. Ví dụ: stress cao ↔ điểm cao, vì cả hai cùng do học nhiều.
- **Interaction (tương tác):** ảnh hưởng của A thay đổi theo nhóm B. Ví dụ: chơi game có hại hơn với người ngủ ít?
- **Làm gì:** `groupby` theo biến nghi ngờ và xem trung bình các biến khác; scatter có `hue=` để tách nhóm; `pd.crosstab` cho 2 biến chữ.
- **Kết luận cần viết:** quan hệ nào là thật, quan hệ nào bị nhiễu. Nhắc: *correlation ≠ causation*.

5.4. Multivariable check (baseline model)

- **Mục đích:** kiểm tra xem khi đưa tất cả biến vào cùng lúc, biến nào vẫn còn ý nghĩa.
- **Làm gì:** một mô hình OLS đơn giản (`statsmodels.formula.api.ols`); so sánh R^2 của mô hình đầy đủ với mô hình rút gọn.
- **Đọc thế nào:** hệ số (coef) = thay đổi của target khi biến tăng 1 đơn vị, giữ các biến khác không đổi. $p > 0.05 \rightarrow$ không còn ý nghĩa khi đã có biến khác.
- **Lưu ý:** đây chỉ là bước kiểm tra trong EDA, chưa phải bước modelling (chưa chia train/test).

6. Summary & Next Steps

Mục tiêu: người đọc chỉ đọc phần này cũng hiểu toàn bộ bài. **Không có code, không có kết quả mới** - chỉ tổng hợp những gì đã tìm ra.

6.1. Key findings

- **Làm gì:** 4–6 gạch đầu dòng, sắp xếp từ quan trọng nhất. Mỗi ý có **con số** và trả lời một câu hỏi ở 0.1.
- **Ví dụ:** *Study hours is the strongest positive driver of grades ($r = 0.73$).*

6.2. Data quality issues

- **Làm gì:** tóm tắt bảng 2.7 trong 2–3 câu: lỗi gì, bao nhiêu %, đã xử lý thế nào.

6.3. Limitations

- **Làm gì:** nêu những điều làm kết luận kém chắc chắn:
 - Dữ liệu giả lập hay thật? Mẫu có đại diện không?
 - Dữ liệu quan sát → chỉ nói "associated with", không nói "causes".
 - Nhóm nhỏ, biến thiếu, biến bị tạo từ quy tắc.

6.4. Recommendations for modelling

- **Làm gì:** biến EDA thành kế hoạch cụ thể cho bước sau:
 - Cần làm sạch gì trước (clip, impute, encode).
 - Giữ / bỏ feature nào (dựa trên VIF và 5.4).
 - Nguy cơ data leakage (ví dụ `stress_level` được tạo từ các feature khác).
 - Mô hình baseline nên thử (Linear Regression) và mô hình so sánh (Random Forest / XGBoost).

Appendix

A. English conclusion templates

Công thức một câu kết luận tốt: **quan sát + con số + ý nghĩa / hệ quả.**

Tình huống	Mẫu câu
Không có lỗi	There are no missing values or duplicated records in the dataset.
Có lỗi	<i>[N] rows ([x]%) have [column] above [limit], which is invalid. These values were clipped to [limit].</i>

Tình huống	Mẫu câu
Phân phối	<i>[Column]</i> is approximately symmetric (skew = <i>[x]</i>), with a mean of <i>[x]</i> and a median of <i>[x]</i> .
Lệch	<i>[Column]</i> is right-skewed, so a log transformation may be needed before modelling.
Categorical	<i>[Group]</i> is the largest group (<i>[x]</i> %), while <i>[group]</i> is small (<i>[x]</i> %), so results for it are less reliable.
Tương quan mạnh	<i>[X]</i> has a strong positive relationship with <i>[target]</i> ($r = [x]$): higher <i>[X]</i> is associated with higher <i>[target]</i> .
Không liên quan	<i>[X]</i> shows no relationship with <i>[target]</i> ($r \approx 0$).
Kiểm định	<i>[Target]</i> differs significantly between <i>[groups]</i> (Kruskal-Wallis, $p < 0.001$, $\epsilon^2 = [x]$, large effect).
Không khác biệt	There is no significant difference in <i>[target]</i> between <i>[groups]</i> ($p = [x]$).
Ngược trực giác	Surprisingly, <i>[X]</i> is positively related to <i>[target]</i> . This is explained by <i>[Z]</i> , which affects both.
Đa cộng tuyến	<i>[X1]</i> and <i>[X2]</i> are highly correlated ($\rho = [x]$, VIF = <i>[x]</i>), so only one should be kept in a linear model.

Từ nổi hữu ích: *However, In contrast, This suggests that, This is consistent with, As a result, Therefore.* Tránh viết "causes" / "proves" với dữ liệu quan sát – dùng "is associated with", "suggests".

B. Final checklist

- ☐ Có mục tiêu và câu hỏi ở đầu bài (0.1)
- ☐ Có bảng variable dictionary với khoảng giá trị hợp lệ (1.2)
- ☐ Kiểm tra trùng lặp đã bỏ cột ID (2.2)
- ☐ Có kiểm tra giá trị vô lý theo domain, không chỉ outlier (2.4)
- ☐ Dữ liệu gốc không bị ghi đè; có bảng cleaning log (2.7)
- ☐ **Mọi cell code đều có kết luận 1–3 câu, kèm con số**
- ☐ Biểu đồ có tiêu đề, nhãn trục; không có subplot trống; không vẽ chồng nhiều biến lên 1 trục

- ☐ Có effect size bên cạnh p-value
- ☐ Mọi kết quả ngược trực giác đều được giải thích
- ☐ VIF không chứa target
- ☐ Summary trả lời đủ các câu hỏi ở 0.1 và có phần Limitations
- ☐ Notebook chạy lại từ đầu đến cuối không lỗi (Restart & Run All)